技术面试题目答题模板 · 总览

技术面试准备材料 · AI 应用 / Agent 开发

> 面向 AI 应用 / Agent 开发岗位，共 11 份主题文档。内容以「原理 + 设计取舍 + 项目落地」为主，答案可直接改写为口述稿。
>
> 项目背景统一使用 **AI4Test（测试全流程多 Agent 平台）** 与 **AgentLearn 系列工程 Demo**，便于在不同题目之间复用同一套素材。

一、文档目录

文档	主题	核心问题
01-Agent基础与架构.md	Agent 基础与架构	Agent 是什么、ReAct、单/多 Agent、运行时、状态机、分层
02-Prompt工程与模型调用.md	Prompt 与模型调用	Prompt 结构、结构化输出、Function Calling、流式、模型选型、成本
03-RAG与知识检索.md	RAG 与检索	切分、Embedding、混合检索、Rerank、多租户、评测
04-工具调用与执行可靠性.md	工具与可靠性	幂等、重试、副作用、沙箱、权限、MCP、并行调用
05-记忆与上下文管理.md	记忆与上下文	四层记忆、压缩、写入/检索/遗忘、冲突、隐私
06-工作流编排与多Agent协作.md	编排与协作	固定 vs 动态、DAG、路由、Handoff、循环、人机协同
07-高并发网关与任务调度.md	网关与调度	容量、限流、排队、缓存、Lease、Checkpoint、优雅取消
08-评测、可观测性与线上排障.md	评测与排障	评测集、指标、归因、Tracing、回归、事故处理
09-安全、权限与风控.md	安全与风控	Prompt Injection、Guardrails、沙箱、审批、审计、风控 Agent
10-系统设计与场景题.md	系统设计	测试平台、知识库、网关、排障、风控、多租户

二、复习路线（建议 2～4 周）

第一阶段：建立主干（3～4 天）

1. **01 Agent 基础与架构**：能画出一个 Agent 系统的分层图，讲清运行时、状态、工具、上下文、编排各自负责什么。
2. **02 Prompt 与模型调用**：能讲清结构化输出、Function Calling、流式、模型选型和成本控制。
3. **04 工具与可靠性**：理解「模型只提议，系统负责执行」，重点是幂等、重试边界和副作用。

第二阶段：补核心能力（4～5 天）

4. **03 RAG**：掌握完整链路和评测方法，能解释为什么「向量检索不是万能的」。
5. **05 记忆与上下文**：区分短期/长期记忆，理解压缩不可逆和记忆污染。
6. **06 编排与多 Agent**：能说清什么时候用固定 Workflow、什么时候用动态路由。

第三阶段：生产化（4～5 天）

7. **07 网关与调度**：容量估算、限流、队列、Lease、Checkpoint、优雅取消。
8. **08 评测与排障**：评测集、归因分析、可观测性、线上事故处理。
9. **09 安全与风控**：Prompt Injection、Guardrails、最小权限、审批、审计。

第四阶段：输出与模拟（3～4 天）

10. **10 系统设计**：按「需求—容量—架构—数据流—失败处理—取舍」练 3 个完整设计题。
11. **串讲项目**：把 AI4Test 讲成 2 分钟、5 分钟、15 分钟三个版本。
12. **模拟追问**：每个设计至少准备「为什么不用另一种方案」「出问题怎么查」「怎么衡量」。

三、答题通用结构

技术题不要一上来堆名词，建议按四层回答：

1. **一句话结论**：先给判断，例如「我会把执行层和编排层分开」。
2. **原理与边界**：这个方案解决什么问题、不解决什么问题。
3. **项目落地**：我在 AI4Test / AgentLearn 里怎么做的，遇到什么坑。
4. **取舍与验证**：代价是什么、怎么衡量、什么情况下会换方案。

面试官更看重的是「你为什么这么选」，而不是「你知道多少名词」。

四、高频 20 题

#	题目	对应文档
1	什么是 Agent？和 Workflow、Chatbot 的区别	01
2	ReAct 的原理和缺点	01
3	什么时候该用多 Agent，什么时候不该	01
4	Agent 运行时需要管理哪些状态	01
5	如何保证结构化输出稳定	02
6	Function Calling 的原理和限制	02
7	如何降低 Token 成本和首字延迟	02

#	题目	对应文档
8	RAG 的完整链路	03
9	向量检索和 BM25 怎么选	03
10	如何评估 RAG 效果	03
11	工具调用的幂等怎么设计	04
12	如何避免重试风暴	04
13	沙箱需要限制哪些维度	04
14	短期记忆和长期记忆怎么配合	05
15	固定 Workflow 和动态 Agent 的边界	06
16	多 Agent 如何路由、如何防止死循环	06
17	高并发 Agent 网关怎么设计	07
18	长任务如何断点续跑	07
19	Agent 评测为什么难、怎么做	08
20	Prompt Injection 怎么防	09

五、项目故事映射

同一套项目素材，可以按题目抽取不同侧面：

题目类型	抽取的侧面
架构设计	provider / gateway / runtime / orchestration 分层；依赖方向约束
可靠性	工具幂等、Lease、Checkpoint、in_flight / uncertain 状态
编排	Agent Pool、能力标签、统一评分、Workflow Validator
上下文	多级压缩、任务状态压缩、检索记忆
高并发	多级限流、准入控制、WFQ、Singleflight、语义缓存
评测	Golden Set、轨迹归因、版本指纹、CI 门禁
安全	Guardrails Pipeline、工具白名单、沙箱、审批
排障	故障上下文、证据驱动假设、受控恢复、经验库

六、使用说明

- 每份文档中的答案都是「可口述版本」，不是论文；面试时按题目删减。
- 涉及数字的地方用真实数据；没有精确数据就用「明显下降」「从不可用变为可用」这类可解释表述。
- 每份文档末尾有「高频追问」，用于自查是否真的理解，而不是背答案。
- 建议先看总览，再按自己的薄弱项选读，不要从第一页顺序背到最后。